深蓝学院
shenlanxueyuan.com

多传感器融合定位

第2章 基于地图的定位

主讲人 任 乾

北京理工大学本硕
自动驾驶从业者

目录

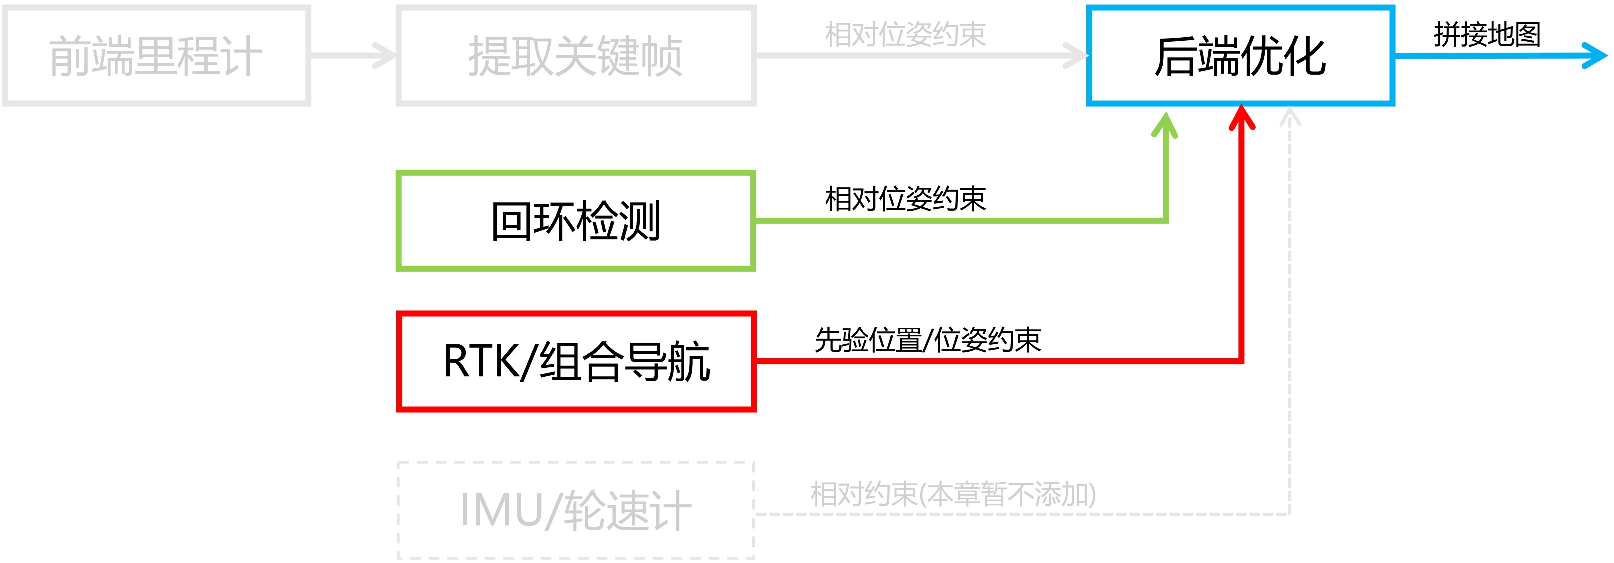

前端里程计
提取关键帧
相对位姿约束
后端优化
拼接地图
回环检测
相对位姿约束
RTK/组合导航
先验位置/位姿约束
IMU/轮速计
相对约束(本章暂不添加)

目录

回环检测


回环检测
有初始相对位姿
ICP系列
NDT系列
第一章已讲
无初始相对位姿
非学习方法
scan context
重点讲解
特征直方图
简略介绍
基于学习方法
segmap
PointNetVLAD
不做讲解

回环检测

基于Scan Context

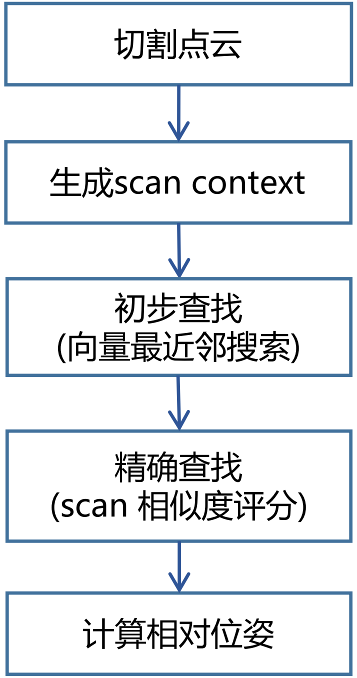

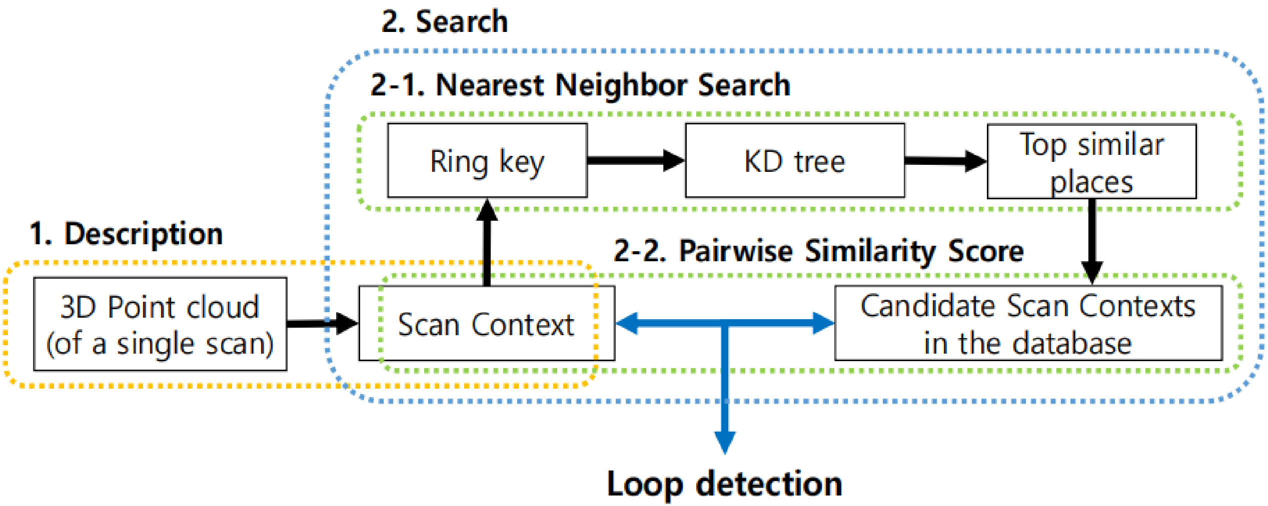

回环检测

基于Scan Context

1) 点云切割

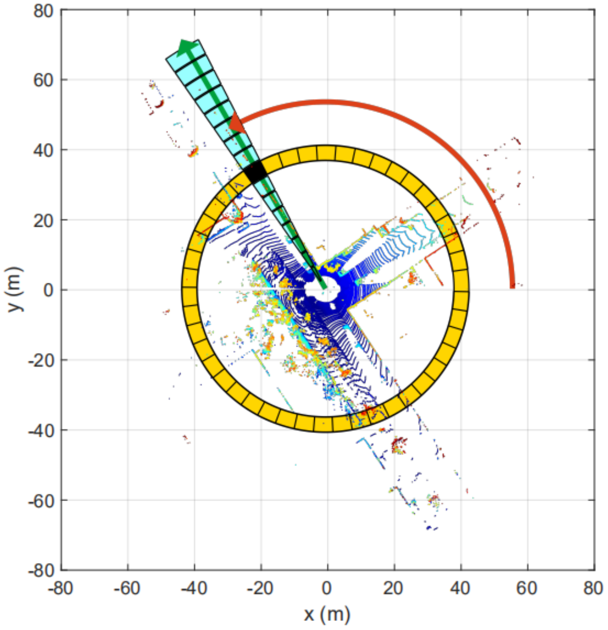

点云分割示意图

a) 沿半径增大方向（绿色箭头方向），把点云空间等分成N_r个圆环。

每个圆环宽度为：

$$d_r = \frac{L_{\max}}{N_r}$$

其中 $L_{\max}$为激光点的最远距离。

b) 把每个圆环切割成N_s等份

分割后，激光点集合$\mathcal{P}$可重新表示为：

$$\mathcal{P} = \bigcup_{i \in [N_r], j \in [N_s]} \mathcal{P}_{ij}$$

其中，$\mathcal{P}_{ij}$表示第i个圆环第j个扇形的分割单元中点的集合。

回环检测

基于Scan Context

2) 生成scan context

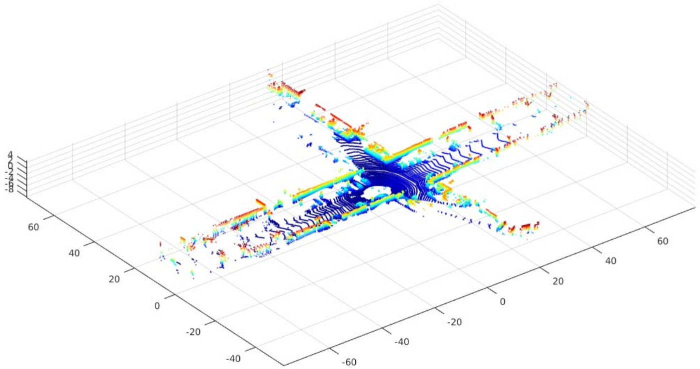

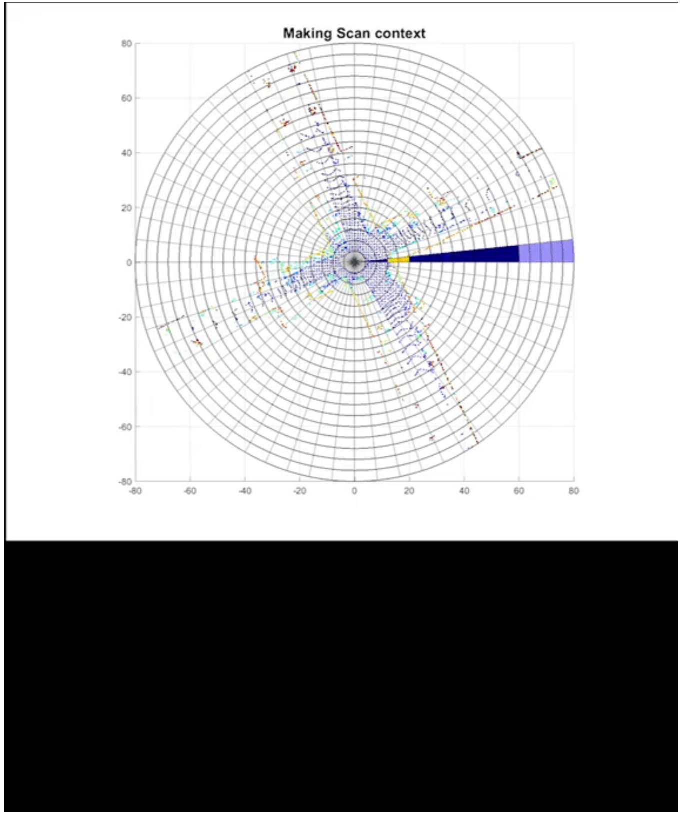

回环检测

基于Scan Context

2) 生成scan context

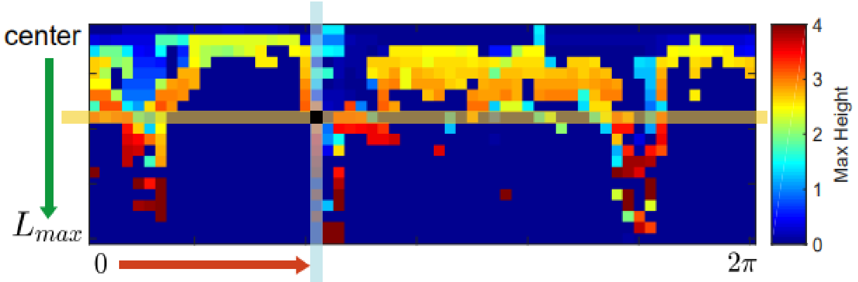

scan context示意图

把分割后的点云对应到$N_r \times N_s$的矩阵I(scan context)中：

a) 矩阵的每一行代表一个圆环；

b) 矩阵的每一列代表一个扇形；

c) 矩阵中每个元素的值代表该分割单元$\mathcal{P}_{ij}$中所有三维点的高度最大值。

回环检测

基于Scan Context

3) 基于scan context的匹配

I^q 为当前帧的scan context　　c_j^q 为 I^q中的第j列

I^c 为历史帧的scan context　　c_j^c 为 I^c中的第j列

两帧scan context的距离函数定义为：

$$d\left(I^q, I^c\right)=\frac{1}{N_s} \sum_{j=1}^{N_s}\left(1-\frac{c_j^q \cdot c_j^c}{\left\|c_j^q\right\|\left\|c_j^c\right\|}\right)$$

两帧scan context间的所有对应的列向量之间越相似，说明两帧点云越相似。距离函数小于某个阈值时，认为该历史帧为回环检测的回环帧。

问题：若当前帧相对于历史帧有旋转，比如同一个地方激光雷达经过时的方向相反，或者该地方为一个十字路口，激光雷达从不同方向经过（如右图所示），此时得到的scan context中列向量的顺序会发生改变，进而导致两帧的距离函数比较大。

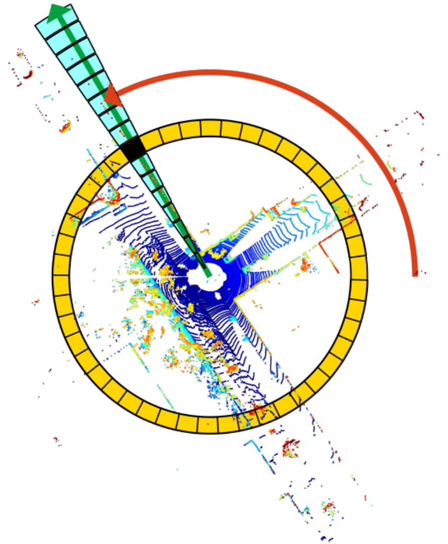

当前帧的点云分割

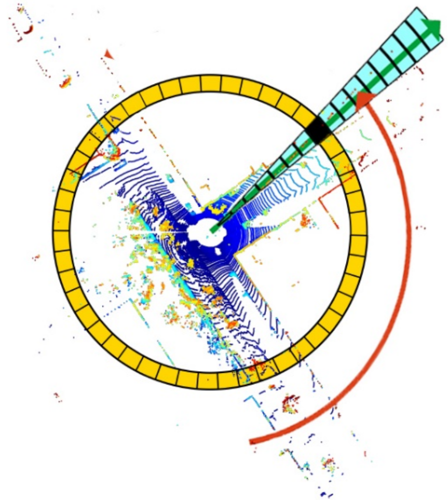

历史帧的点云分割

回环检测

基于Scan Context

3) 基于scan context的匹配

I^q 为当前帧的scan context

I^c 为历史帧的scan context

方法：

$$D\left(I^q, I^c\right) = \min_{n \in [N_s]} d\left(I^q, I_n^c\right)$$

将历史帧I^c按列平移，得到$[N_s]$个scan context，依次与当前帧的scan context计算距离，选择距离最小的那个。

根据以上方法，找出所有候选相似帧中和当前帧距离最小的，即为闭环匹配的帧。

I^q

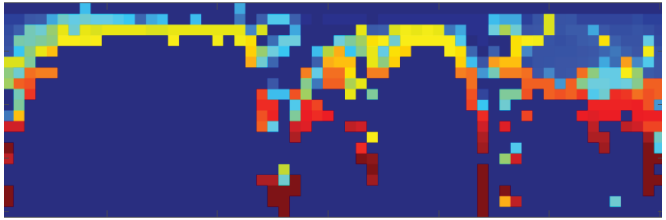

I^c

I_n^c

回环检测

基于Scan Context

4) 计算相对位姿

假设距离最小时，对应的列的平移量为：

$$n^* = \underset{n \in [N_s]}{\operatorname{argmin}} d\left(I^q, I_n^c\right)$$

则它代表两帧之间有旋转，旋转的角度为：

$$\phi = \frac{2\pi}{N_s} * n^*$$

以上旋转量则可作为ICP或NDT匹配的初始位姿，用于精确匹配得到闭环约束的相对位姿。

回环检测

基于Scan Context

5) 解决时间复杂度问题

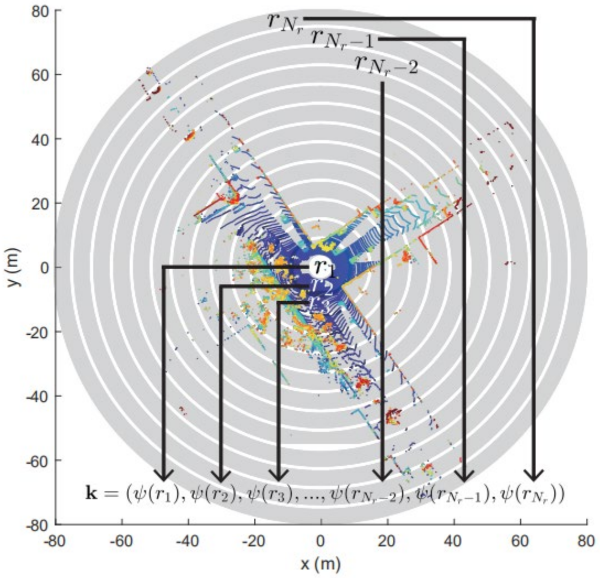

目的： scan context可以用矩阵对应列的相似度来计算两帧的相似性，但是遍历所有历史帧的相似度计算量较高，需要做一个快速初步筛选。

思路： 相似帧之间，落在同等半径的圆环中点的数量应相似，可用来快速查找。

方法：

a) 每帧生成一个向量：

$$\mathbf{k}=\left(\psi\left(r_1\right),\ldots,\psi\left(r_{N_r}\right)\right),\ \text{where}\ \psi: r_i \rightarrow \mathbb{R}$$

其中

$$\psi\left(r_i\right)=\frac{\left\|r_i\right\|_0}{N_s}$$

$\left\|r_i\right\|_0$ 表示半径 r_i 对应的圆环中非空分割单元的个数。

b) 根据a)中计算的向量，所有历史帧共同构建KDTree；

c) 使用当前帧对应的向量，在KDTree中查找，找出n个可能的相似帧，再通过scan context精确查找。

回环检测

基于Scan Context

案例：

方法： LeGO-LOAM + scan context 闭环检测

代码：https://github.com/irapkaist/SC-LeGO-LOAM

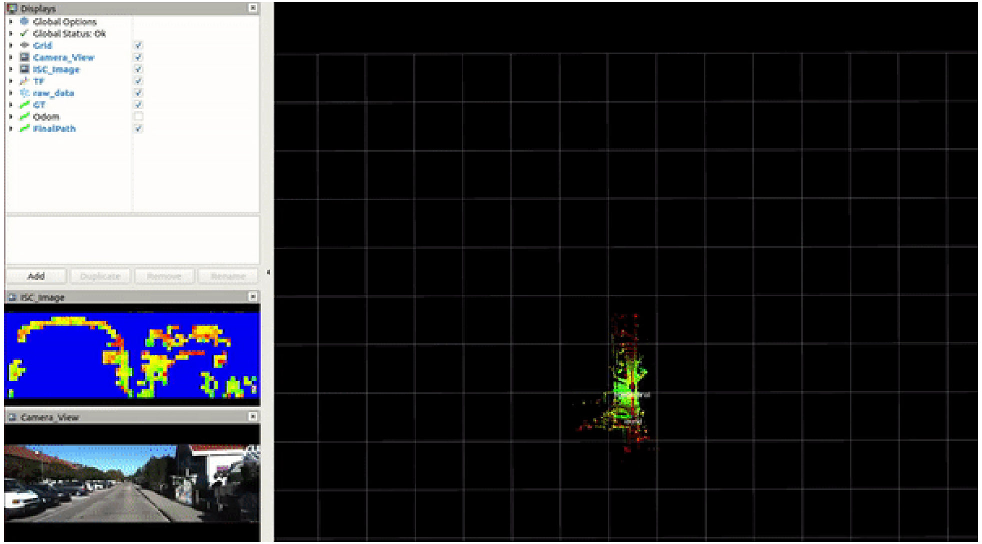

回环检测

基于直方图

论文题目：A fast, complete, point cloud based loop closure for LiDAR odometryand mapping
应用案例：loam_livox
开源代码：https://github.com/hku-mars/loam_livox

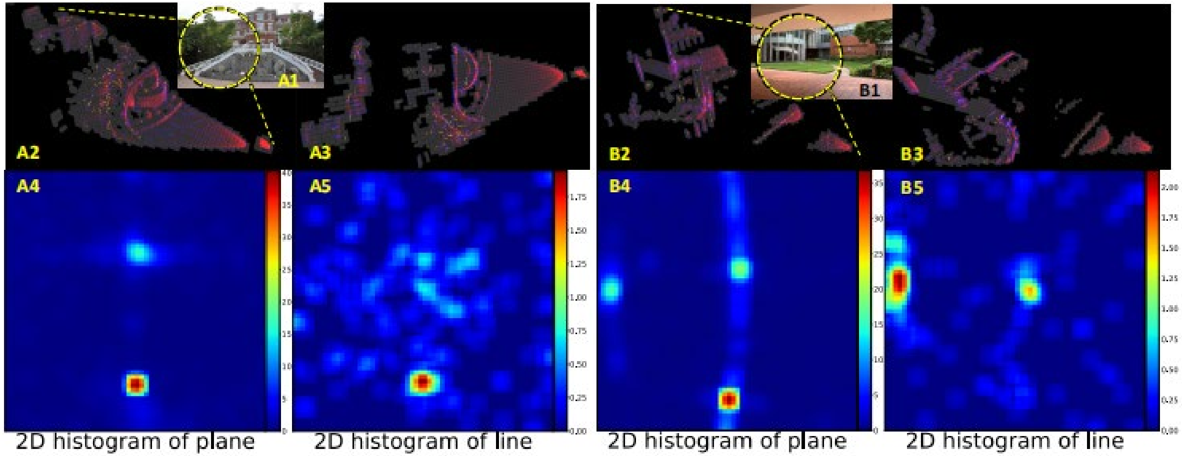

目录

后端优化

1. 后端优化基本原理

目的：利用回环检测结果和惯导先验位姿修正里程计误差。

回环在此处提供的是两帧之间的相对位姿。

观测：

1) 连续两帧的相对位姿观测

2) 闭环匹配得到的相对位姿观测

3) 组合导航提供的先验位姿观测

1)和2)的观测构成了基于回环的位姿修正

1)和3)的观测构成了基于先验观测的位姿修正

当然1) 2) 3) 也可以同时使用。

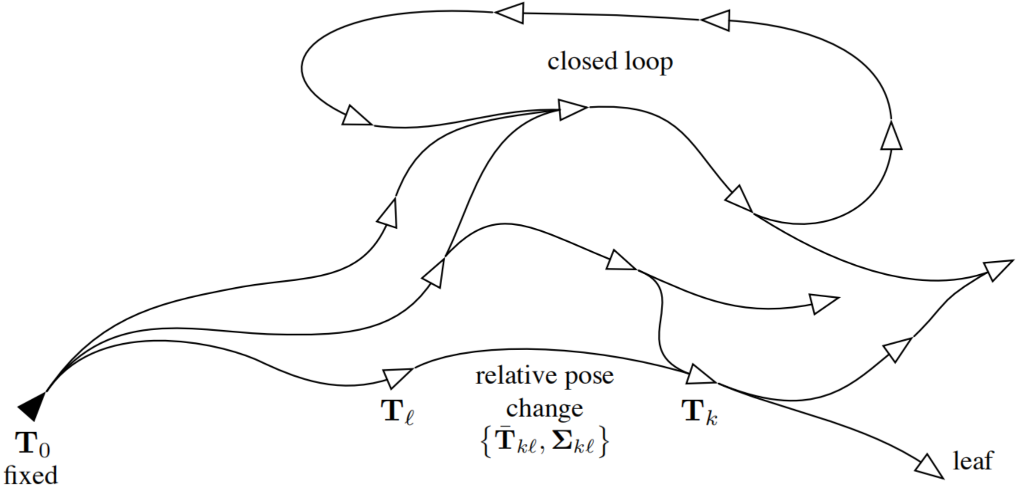

后端优化示意

后端优化

2. 李群、李代数基本知识

三维旋转上的定义：

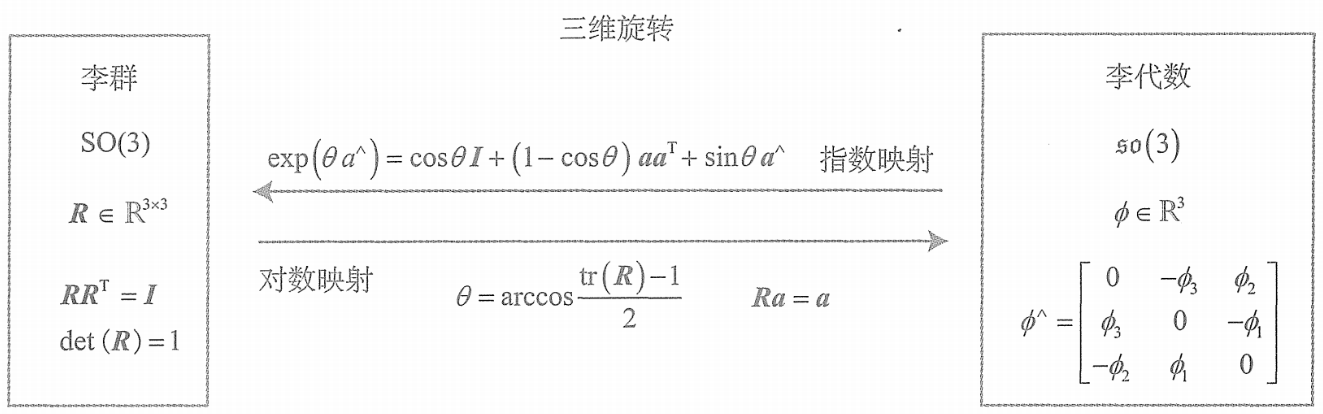

2. 李群、李代数基本知识

三维变换上的定义：

三维变换

李群

SE(3)

$T \in \mathbb{R}^{4\times4}$

$$T = \begin{bmatrix} R & t \\ 0^T & 1 \end{bmatrix}$$

$$\exp(\xi^\wedge) = \begin{bmatrix} \exp(\phi^\wedge) & J\rho \\ 0^T & 1 \end{bmatrix}$$

$$J = \frac{\sin\theta}{\theta} I + \left(1 - \frac{\sin\theta}{\theta}\right) a a^T + \frac{1-\cos\theta}{\theta} a^\wedge$$

指数映射

对数映射

$$\theta = \arccos \frac{\mathrm{tr}(R) - 1}{2} \qquad Ra = a \qquad t = J\rho$$

李代数

$\mathfrak{se}(3)$

$$\xi = \begin{bmatrix} \rho \\ \phi \end{bmatrix} \in \mathbb{R}^6$$

$$\xi^\wedge = \begin{bmatrix} \phi^\wedge & \rho \\ 0^T & 0 \end{bmatrix}$$

2. 李群、李代数基本知识

BCH公式

$$\ln(\exp(A)\exp(B)) = A + B + \frac{1}{2}[A,B] + \frac{1}{12}[A,[A,B]] - \frac{1}{12}[B,[A,B]] + \cdots$$

SO(3)下的李括号定义为

$$[\phi_1, \phi_2] = (\Phi_1\Phi_2 - \Phi_2\Phi_1)^{\vee}$$

SE(3)下的李括号定义为

$$[\xi_1, \xi_2] = (\xi_1^{\wedge}\xi_2^{\wedge} - \xi_2^{\wedge}\xi_1^{\wedge})^{\vee}$$

其中

$$\Phi = \phi^{\wedge} = \begin{bmatrix} 0 & -\phi(3) & \phi(2) \\ \phi(3) & 0 & -\phi(1) \\ -\phi(2) & \phi(1) & 0 \end{bmatrix}$$

2. 李群、李代数基本知识

SO(3)对应的BCH公式

$$\ln\left(\exp\left(\phi_1^{\wedge}\right)\exp\left(\phi_2^{\wedge}\right)\right)^{\vee} \approx \begin{cases} J_l\left(\phi_2\right)^{-1}\phi_1+\phi_2 & \text{，当 } \phi_1 \text{ 为小量} \\ J_r\left(\phi_1\right)^{-1}\phi_2+\phi_1 & \text{，当 } \phi_2 \text{ 为小量} \end{cases}$$

其中左乘雅可比为

$$J_l = \frac{\sin\theta}{\theta}I + \left(1-\frac{\sin\theta}{\theta}\right)aa^{\mathrm{T}} + \frac{1-\cos\theta}{\theta}a^{\wedge}$$

即

$$J_l^{-1} = \frac{\theta}{2}\cot\frac{\theta}{2}I + \left(1-\frac{\theta}{2}\cot\frac{\theta}{2}\right)aa^{\mathrm{T}} - \frac{\theta}{2}a^{\wedge}$$

右乘雅可比仅需要在左乘雅可比的基础上对自变量取负号，即

$$J_r(\phi) = J_l(-\phi)$$

2. 李群、李代数基本知识

SE(3)对应的BCH公式

$$\ln\left(\exp\left(\boldsymbol{\xi}_1^{\wedge}\right)\exp\left(\boldsymbol{\xi}_2^{\wedge}\right)\right)^{\vee} \approx \begin{cases} \mathcal{J}_{\ell}\left(\boldsymbol{\xi}_2\right)^{-1}\boldsymbol{\xi}_1+\boldsymbol{\xi}_2 \text{，当 } \boldsymbol{\xi}_1 \text{ 为小量} \\ \mathcal{J}_{r}\left(\boldsymbol{\xi}_1\right)^{-1}\boldsymbol{\xi}_2+\boldsymbol{\xi}_1 \text{，当 } \boldsymbol{\xi}_2 \text{ 为小量} \end{cases}$$

由于SE(3)上的雅可比形式过于复杂，此处直接给出本章所用到的近似形式如下。详细内容可参考《机器人中的状态估计》中公式7.83的推导过程。

$$\mathcal{J}_r^{-1}(\boldsymbol{\xi}) \approx I+\frac{1}{2}\begin{bmatrix} \phi^{\wedge} & \rho^{\wedge} \\ 0 & \phi^{\wedge} \end{bmatrix}$$

若 $\boldsymbol{\xi}$ 非常小，则该雅可比可以直接使用单位阵，此时有

$$\ln\left(\exp\left(\boldsymbol{\xi}_1^{\wedge}\right)\exp\left(\boldsymbol{\xi}_2^{\wedge}\right)\right)^{\vee} \approx \ln\left(\exp\left(\boldsymbol{\xi}_1^{\wedge}+\boldsymbol{\xi}_1^{\wedge}\right)\right)^{\vee}$$

2. 李群、李代数基本知识

SO(3)上的伴随性质

$$R\exp\left(p^{\wedge}\right)R^{\mathrm{T}}=\exp\left((Rp)^{\wedge}\right)$$

SE(3)上的伴随性质

$$T\exp\left(\xi^{\wedge}\right)T^{-1}=\exp\left((\mathrm{Ad}(T)\xi)^{\wedge}\right)$$

其中伴随矩阵的定义如下

$$\mathrm{Ad}(T)=\begin{bmatrix} R & t^{\wedge}R \\ 0 & R \end{bmatrix}$$

后端优化

3. 基于回环的位姿修正

位姿图优化是把所有的观测和状态放在一起优化，残差项是前面所讲残差项的总和。

在实际使用中，各残差会被分配一个权重，也就是信息矩阵，它相当于对残差进行加权。

考虑信息矩阵后，总的残差项可以表示为：

$$\mathbf{F}(\mathbf{x}) = \sum_{\langle i,j\rangle \in \mathcal{C}} \underbrace{\mathbf{e}_{ij}^T \boldsymbol{\Omega}_{ij} \mathbf{e}_{ij}}_{\mathbf{F}_{ij}}$$

此时优化问题可以表示为：

$$\mathbf{x}^* = \underset{\mathbf{x}}{\operatorname{argmin}} \mathbf{F}(\mathbf{x})$$

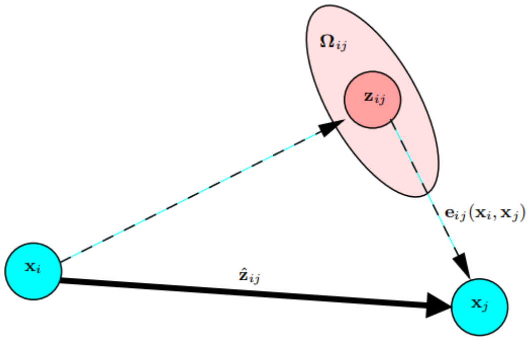

单个残差项

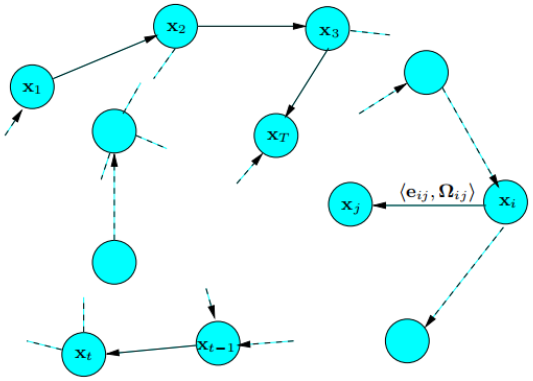

多个残差项组成位姿图

后端优化

3. 基于回环的位姿修正

第i和j帧之间的观测，在李群SE(3)上可以表示为

$$\boldsymbol{\Delta T}_{ij} = \boldsymbol{T}_i^{-1}\boldsymbol{T}_j$$

也可以在李代数上表示为

$$\Delta\boldsymbol{\xi}_{ij} = \boldsymbol{\xi}_i^{-1} \circ \boldsymbol{\xi}_j = \ln\left(\boldsymbol{T}_i^{-1}\boldsymbol{T}_j\right)^{\vee}$$

若位姿没有误差，则上面两个式子是精确相等的，但当位姿有误差存在时，便可以使用等式的左右两端计算残差项。

$$\begin{aligned}\boldsymbol{e}_{ij} &= \ln\left(\Delta\boldsymbol{T}_{ij}^{-1}\boldsymbol{T}_i^{-1}\boldsymbol{T}_j\right)^{\vee} \\ &= \ln\left(\exp\left((-\boldsymbol{\xi}_{ij})^{\wedge}\right)\exp\left((-\boldsymbol{\xi}_i)^{\wedge}\right)\exp\left(\boldsymbol{\xi}_j^{\wedge}\right)\right)^{\vee}\end{aligned}$$

位姿图优化的思想是通过调整状态量(即位姿)，使残差项的值最小化，这就需要用残差项对位姿求雅可比，才能使用梯度下降方法进行优化。

求雅可比的方式是对位姿添加扰动，此时残差表示为：

$$\hat{\boldsymbol{e}}_{ij} = \ln\left(\boldsymbol{T}_{ij}^{-1}\boldsymbol{T}_i^{-1}\exp\left((-\boldsymbol{\delta\xi}_i)^{\wedge}\right)\exp\left(\delta\boldsymbol{\xi}_j^{\wedge}\right)\boldsymbol{T}_j\right)^{\vee}$$

后端优化

3. 基于回环的位姿修正

进一步对前面的式子进行化简

$$
\begin{aligned}
\hat{\boldsymbol{e}}_{ij} &= \ln\left(\boldsymbol{T}_{ij}^{-1}\boldsymbol{T}_i^{-1}\exp\left((-\boldsymbol{\delta\xi}_i)^\wedge\right)\exp\left(\delta\boldsymbol{\xi}_j^\wedge\right)\boldsymbol{T}_j\right)^\vee \\
&= \ln\left(\boldsymbol{T}_{ij}^{-1}\boldsymbol{T}_i^{-1}\boldsymbol{T}_j\exp\left(\left(-\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)\boldsymbol{\delta\xi}_i\right)^\wedge\right)\exp\left(\left(\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)\boldsymbol{\delta\xi}_j\right)^\wedge\right)\right)^\vee \\
&\approx \ln\left(\exp(\boldsymbol{e}_{ij})\exp\left(\left(-\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)\boldsymbol{\delta\xi}_i\right)^\wedge+\left(\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)\boldsymbol{\delta\xi}_j\right)^\wedge\right)\right)^\vee \\
&\approx \boldsymbol{e}_{ij} - \mathcal{J}_r^{-1}(e_{ij})\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)\boldsymbol{\delta\xi}_i + \mathcal{J}_r^{-1}(e_{ij})\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)\boldsymbol{\delta\xi}_j
\end{aligned}
$$

上面的式子表明，残差关于T_i的雅克比为

$$
A_{ij} = \frac{\partial \boldsymbol{e}_{ij}}{\partial \boldsymbol{\delta\xi}_i} = -\mathcal{J}_r^{-1}(\boldsymbol{e}_{ij})\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)
$$

残差关于T_j的雅克比为

$$
B_{ij} = \frac{\partial \boldsymbol{e}_{ij}}{\partial \boldsymbol{\delta\xi}_j} = \mathcal{J}_r^{-1}(\boldsymbol{e}_{ij})\operatorname{Ad}\left(\boldsymbol{T}_j^{-1}\right)
$$

其中

$$
\mathcal{J}_r^{-1}(\boldsymbol{e}_{ij}) \approx I + \frac{1}{2}\begin{bmatrix} \phi_e^\wedge & \rho_e^\wedge \\ 0 & \phi_e^\wedge \end{bmatrix}
$$

后端优化

3. 基于回环的位姿修正

为了找到梯度方向，需要对残差进行一阶泰勒展开

$$
\begin{aligned}
&\mathbf{e}_{ij}\left(\mathbf{x}_i+\Delta\mathbf{x}_i, \mathbf{x}_j+\Delta\mathbf{x}_j\right) \\
&= \mathbf{e}_{ij}(\mathbf{x}+\Delta\mathbf{x}) \\
&\approx \mathbf{e}_{ij}+\mathbf{J}_{ij}\Delta\mathbf{x}
\end{aligned}
$$

其中 J_{ij} 即为前面推导的残差关于位姿的雅可比组成的矩阵

$$
\mathbf{J}_{ij} = (0\cdots 0\ \underbrace{\mathbf{A}_{ij}}_{\text{node } i}\ \mathbf{0}\cdots 0\ \underbrace{\mathbf{B}_{ij}}_{\text{node } j}\ \mathbf{0}\cdots 0)
$$

对于每一个残差块，便有

$$
\begin{aligned}
&\mathbf{F}_{ij}(\mathbf{x}+\Delta\mathbf{x}) \\
&= \mathbf{e}_{ij}(\mathbf{x}+\Delta\mathbf{x})^T\Omega_{ij}\mathbf{e}_{ij}(\mathbf{x}+\Delta\mathbf{x}) \\
&\approx \left(\mathbf{e}_{ij}+\mathbf{J}_{ij}\Delta\mathbf{x}\right)^T\Omega_{ij}\left(\mathbf{e}_{ij}+\mathbf{J}_{ij}\Delta\mathbf{x}\right) \\
&= \underbrace{\mathbf{e}_{ij}^T\Omega_{ij}\mathbf{e}_{ij}}_{c_{ij}} + 2\underbrace{\mathbf{e}_{ij}^T\Omega_{ij}\mathbf{J}_{ij}}_{\mathbf{b}_{ij}^T}\Delta\mathbf{x} + \Delta\mathbf{x}^T\underbrace{\mathbf{J}_{ij}^T\Omega_{ij}\mathbf{J}_{ij}}_{\mathbf{H}_{ij}}\Delta\mathbf{x} \\
&= c_{ij} + 2\mathbf{b}_{ij}^T\Delta\mathbf{x} + \Delta\mathbf{x}^T\mathbf{H}_{ij}\Delta\mathbf{x}
\end{aligned}
$$

其中

$$
\mathbf{H}_{ij} = \begin{pmatrix}
\ddots & & & & \\
& \mathbf{A}_{ij}^T\Omega_{ij}\mathbf{A}_{ij} & \cdots & \mathbf{A}_{ij}^T\Omega_{ij}\mathbf{B}_{ij} & \\
\vdots & & \ddots & \vdots & \\
& \mathbf{B}_{ij}^T\Omega_{ij}\mathbf{A}_{ij} & \cdots & \mathbf{B}_{ij}^T\Omega_{ij}\mathbf{B}_{ij} & \\
\ddots & & & &
\end{pmatrix}
$$

$$
\mathbf{b}_{ij} = \begin{pmatrix}
\vdots \\
\mathbf{A}_{ij}^T\Omega_{ij}\mathbf{e}_{ij} \\
\vdots \\
\mathbf{B}_{ij}^T\Omega_{ij}\mathbf{e}_{ij} \\
\vdots
\end{pmatrix}
$$

后端优化

3. 基于回环的位姿修正

因此总的残差项可以表示为

$$
\begin{aligned}
\mathbf{F}(\mathbf{x}+\Delta\mathbf{x}) &= \sum_{\langle i,j\rangle\in\mathcal{C}} \mathbf{F}_{ij}(\mathbf{x}+\Delta\mathbf{x}) \\
&\approx \sum_{\langle i,j\rangle\in\mathcal{C}} \left(\mathrm{c}_{ij} + 2\mathbf{b}_{ij}^T\Delta\mathbf{x} + \Delta\mathbf{x}^T\mathbf{H}_{ij}\Delta\mathbf{x}\right) \\
&= \mathrm{c} + 2\mathbf{b}^T\Delta\mathbf{x} + \Delta\mathbf{x}^T\mathbf{H}\Delta\mathbf{x}
\end{aligned}
$$

若要误差最小，只需使得

$$\mathbf{H}\Delta\mathbf{x} = -\mathbf{b}$$

根据修正量，修正X的值，即完成一次迭代

$$\mathbf{x}^* = \mathbf{x} + \Delta\mathbf{x}$$

多次迭代，直至残差满足收敛条件时，则终止循环，完成优化。

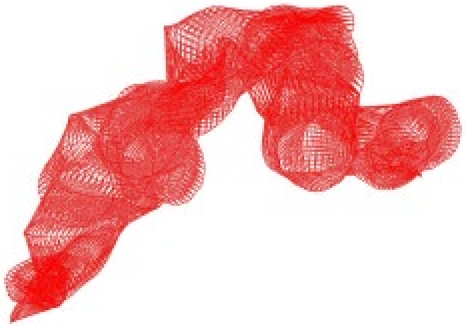

优化前

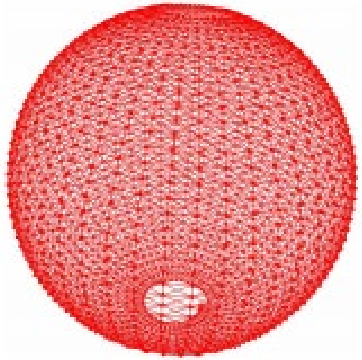

优化后

4. 基于先验观测的位姿修正

先验观测是一元边，它不像前面所述的帧间观测连接两个位姿状态，而是只连接一个位姿状态量，它直接给出的就是该状态量的观测值，因此它对应的残差就是观测值与状态量之间的差异，即

$$\begin{aligned} \boldsymbol{e}_i &= \ln\left(\boldsymbol{Z}_i^{-1}\boldsymbol{T}_i\right)^{\vee} \\ &= \ln\left(\exp\left((-\boldsymbol{\xi}_{zi})^{\wedge}\right)\exp\left(\boldsymbol{\xi}_i^{\wedge}\right)\right)^{\vee} \end{aligned}$$

对残差添加扰动，可得

$$\hat{\boldsymbol{e}}_i = \ln\left(\boldsymbol{Z}_i^{-1}\exp\left(\delta\boldsymbol{\xi}_i^{\wedge}\right)\boldsymbol{T}_i\right)^{\vee}$$

利用伴随性质和BCH公式进行化简，可得

$$\begin{aligned} \hat{\boldsymbol{e}}_i &= \ln\left(\boldsymbol{Z}_i^{-1}\boldsymbol{T}_i\exp\left(\left(\operatorname{Ad}\left(\boldsymbol{T}_i^{-1}\right)\boldsymbol{\delta\xi}_i\right)^{\wedge}\right)\right)^{\vee} \\ &= \ln\left(\exp\left(\boldsymbol{e}_i\right)\exp\left(\left(\operatorname{Ad}\left(\boldsymbol{T}_i^{-1}\right)\boldsymbol{\delta\xi}_i\right)^{\wedge}\right)\right)^{\vee} \\ &\approx e_i + \mathcal{J}_r^{-1}\left(\boldsymbol{e}_i\right)\operatorname{Ad}\left(\boldsymbol{T}_i^{-1}\right)\boldsymbol{\delta\xi}_i \end{aligned}$$

因此，残差关于T_i的雅可比为

$$\frac{\partial \boldsymbol{e}_i}{\partial \boldsymbol{\delta\xi}_i} = \mathcal{J}_r^{-1}\left(\boldsymbol{e}_i\right)\operatorname{Ad}\left(\boldsymbol{T}_i^{-1}\right)$$

其中

$$\mathcal{J}_r^{-1}\left(e_i\right) \approx I + \frac{1}{2}\begin{bmatrix} \phi_e^{\wedge} & \rho_e^{\wedge} \\ 0 & \phi_e^{\wedge} \end{bmatrix}$$

后面的推导过程，便与相对位姿做观测的推导过程完全一致。

此外，部分场合提供的观测只有位置，没有姿态，比如只有RTK，而没有组合导航，这里的残差便只剩下位置误差。相应的雅可比公式，可自行推导。

目录

点云地图建立

1. 整体流程

建图流程设计的核心原则是准确、高效地把里程计相对位姿、回环相对位姿、惯导先验位姿进行融合。

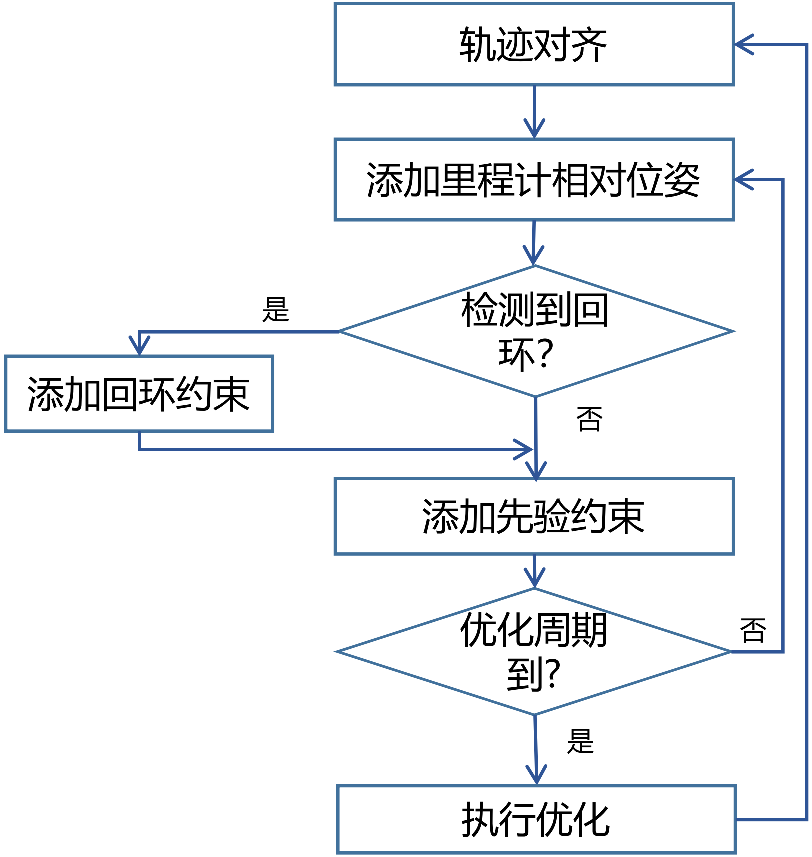

点云地图建立流程图

点云地图建立

2. 畸变补偿

1) 产生原因

一帧点云中的激光点是不同时刻采集的，激光点的坐标原点是采集时刻的雷达位姿。雷达在不同时刻的位姿有变化时，各激光点原点不一致，拼接成一帧时，点云的形状便和实际物体形状不一致。

2) 补偿方法

对每个激光点坐标做补偿，补偿量为激光点原点(即当时雷达坐标)相对于该帧起始时刻的变化。

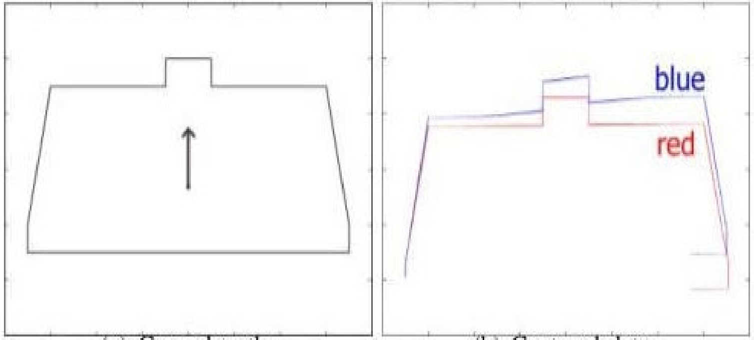

(a) Ground truth (b) Captured data

点云地图建立

2. 畸变补偿

3) 补偿公式

假设一帧点云中，起始时刻雷达的位姿为

$$T_0 = \begin{bmatrix} R_0 & t_0 \\ 0 & 1 \end{bmatrix}$$

第i个激光点采集时，雷达的位姿为

$$T_i = \begin{bmatrix} R_i & t_i \\ 0 & 1 \end{bmatrix}$$

第i个激光点的坐标为

$$P_i = \begin{bmatrix} p_{ix} & p_{iy} & p_{iz} \end{bmatrix}^T$$

则第i个激光点补偿畸变后的坐标应该为

$$\bar{P}_i = T_0^{-1} T_i P_i$$

上式可以理解为，只需要计算0到i时刻，激光雷达的相对旋转和相对平移变化即可。

实际上，雷达点云是局部坐标系下的表示，当以0时刻雷达的位姿为基准坐标系时，此时T_0即为单位阵，T_i即为0到i时刻的相对旋转和平移。

此时有

$$R_i = w \bigtriangledown t$$

$$t_i = V \bigtriangledown t$$

即，只需要知道0到i时刻的平均角速度和平均速度即可。

点云地图建立

3. 建图流程代码讲解

基于g2o的代码实现。

对照代码框架，讲解回环约束和先验观测的添加流程。

最终效果建图

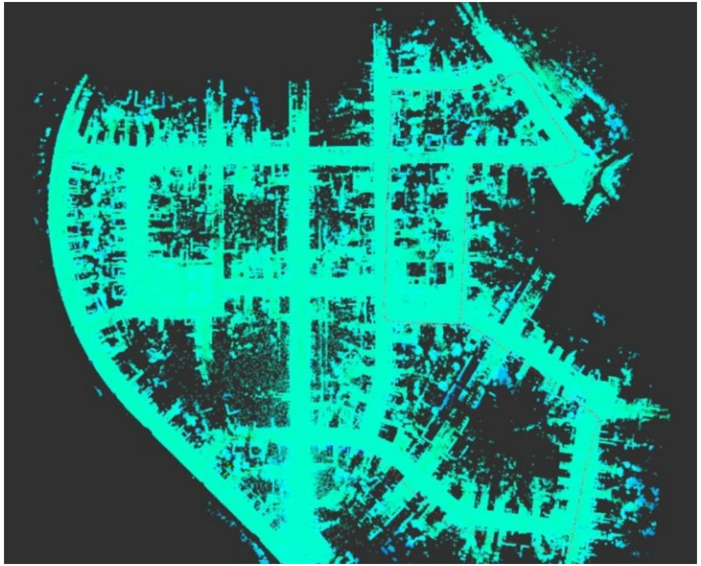

目录

基于地图的定位

1. 整体流程

在地图匹配中，鲁棒性和运行速度更加重要，因此实际使用中，基于NDT的匹配使用更广泛。

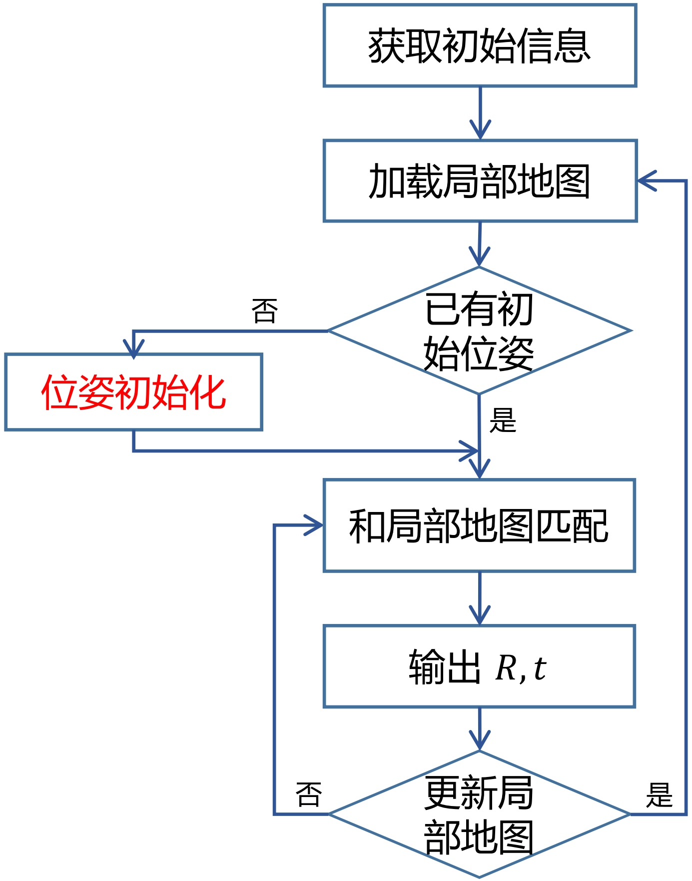

基于地图定位流程图

基于地图的定位

2. 位姿初始化

由于NDT匹配需要较准确的初始位姿，因此在定位之前需要初始化环节，给出载体的初始位姿。

按照难度由低到高，常见的初始化需求有这样几种：

1）已知位姿的初始化

2）位置已知而姿态位置的初始化

3）位置和姿态均未知的初始化

作业

1. 闭环修正及精度评价

提供的工程框架中已经给出了闭环的流程和实现，但是是基于ICP的，这是在已知粗略位姿情况下的实现方式。在未知粗略位姿情况下，闭环检测的实现难度会加大。

要求使用前面讲过的scan context，实现此功能。并和已有的图优化功能完成对接，实现修正。并最终给出修正前后的轨迹精度对比。

2. 位姿初始化

提供的工程框架中已经给出了位姿初始化功能，但是是在起始位置的，并且是基于已知粗略位姿的。

要求实现地图中任意位置的位姿初始化，可以从三种难度等级中任选一种，难度越高，得分越高。

感谢聆听！

Thanks for Listening